


第六章 非线性规划

- 非线性规划问题及其数学模型
- 非线性规划解析解法
- 非线性规划数值解法
- 非线性规划与人工智能



非线性规划的解析解法

➤ 非线性规划问题及其数学模型

➤ 非线性规划解析解法

□ 无约束极值问题

- 一阶条件
- 二阶条件

□ 有约束极值问题:

- 等式约束
- 不等式约束 (**Kuhn-Tucker**条件)
- 一般约束

➤ 凸规划

非线性规划的数学模型

$$\min f(\mathbf{x})$$


$$\text{s.t.} \quad h_i(\mathbf{x}) = 0 \quad i = 1, 2, \dots, m$$

$$g_j(\mathbf{x}) \geq 0 \quad j = 1, 2, \dots, l$$

$$\mathbf{x} \in R^n$$

以求最小值为标准问题

非线性规划解的类型



■ 局部极小点: $\exists \varepsilon > 0$, 满足 $f(\mathbf{x}^*) \leq f(\mathbf{x})$, $\mathbf{x} \in N(\mathbf{x}^*, \varepsilon) \cap \text{可行域}$

■ 全局极小点（最小点）: $f(\mathbf{x}^*) \leq f(\mathbf{x})$, $\mathbf{x} \in \text{可行域}$

严格极小点: “<”

问题: 规划的目标是找哪一种极小点?

非线性规划的解析解

➤ 非线性规划问题及其数学模型

➤ 非线性规划解析解法

□ 无约束极值问题

- 一阶条件
- 二阶条件

□ 有约束极值问题:

- 等式约束
- 不等式约束 (**Kuhn-Tucker**条件)
- 一般约束

➤ 凸规划

无约束极值问题

$$\min f(\boldsymbol{x}) \quad \boldsymbol{x} \in R^n$$

- 一阶极值条件（必要条件）
- 二阶极值条件（必要条件、充分条件）

一阶极值条件（必要条件）

驻点条件

$$\nabla f(\mathbf{x}^*) = \left. \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} \right|_{\mathbf{x}=\mathbf{x}^*} = \mathbf{0}$$

梯度

$$\nabla f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f(\mathbf{x})}{\partial x_1} \\ \frac{\partial f(\mathbf{x})}{\partial x_2} \\ \vdots \\ \frac{\partial f(\mathbf{x})}{\partial x_n} \end{bmatrix}$$

$$f(\mathbf{x} + \Delta\mathbf{x}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^T \Delta\mathbf{x} + O(\|\Delta\mathbf{x}\|)$$

梯度的几何性质

- 假设 \mathbf{p}_t 为目标等值面上的切向矢量， λ 为足够小的正数，有

$$f(\mathbf{x} + \lambda \mathbf{p}_t) - f(\mathbf{x}) \approx \lambda \nabla f(\mathbf{x})^T \mathbf{p}_t = 0$$

- $\nabla f(\mathbf{x})$ 与目标函数等值面的切面正交，为等值面在 \mathbf{x} 的**法向量**



- \mathbf{x} 的梯度方向 $\nabla f(\mathbf{x})$ 是 \mathbf{x} 点目标函数值 $f(\mathbf{x})$ **增长最快**的方向

$$f(\mathbf{x} + \lambda \mathbf{p}) - f(\mathbf{x}) \approx \lambda \nabla f(\mathbf{x})^T \mathbf{p}$$

梯度图示

$$f(\mathbf{x}) = x_1^2 + x_2^2$$

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 \\ 2x_2 \end{bmatrix}$$



无约束极值问题

$$\min f(\mathbf{x}) \quad \mathbf{x} \in R^n$$

- 一阶极值条件（必要条件）
- 二阶极值条件（必要条件、充分条件）

Taylor公式的二阶展开

$$f(\mathbf{x} + \Delta\mathbf{x}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^T \Delta\mathbf{x} + \frac{1}{2} \Delta\mathbf{x}^T \nabla^2 f(\mathbf{x}) \Delta\mathbf{x} + O(\|\Delta\mathbf{x}\|^2)$$

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f(\mathbf{x})}{\partial x_1^2} & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_2^2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \dots & \vdots \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_n^2} \end{bmatrix}$$

Hesse Matrix

二阶极小值条件（必要条件）

$$f(\mathbf{x} + \Delta\mathbf{x}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^T \Delta\mathbf{x} + \frac{1}{2} \Delta\mathbf{x}^T \nabla^2 f(\mathbf{x}) \Delta\mathbf{x} + O(\|\Delta\mathbf{x}\|^2)$$

$$\nabla f(\mathbf{x}^*) = \mathbf{0} \quad \nabla^2 f(\mathbf{x}^*) \geq 0$$

局部极小值 \Rightarrow “ \geq ” 半正定

严格局部极小值 \Rightarrow “ $>$ ” 正定

局部极大值 \Rightarrow “ \leq ” 半负定

严格局部极大值 \Rightarrow “ $<$ ” 负定

为什么不是充分条件？

矩阵的正定与负定

二次型: $\mathbf{x}^T \mathbf{A} \mathbf{x} = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j$ \mathbf{A} 为对称矩阵

$\forall \mathbf{x} \neq 0$ $\mathbf{x}^T \mathbf{A} \mathbf{x} > 0$ \longrightarrow $\mathbf{A} > 0$ 正定矩阵


$\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0$ \longrightarrow $\mathbf{A} \geq 0$ 半正定矩阵

$\mathbf{x}^T \mathbf{A} \mathbf{x} < 0$ \longrightarrow $\mathbf{A} < 0$ 负定矩阵

$\mathbf{x}^T \mathbf{A} \mathbf{x} \leq 0$ \longrightarrow $\mathbf{A} \leq 0$ 半负定矩阵

例1: Hesse矩阵为正定阵

$$f(\mathbf{x}) = x_1^2 + x_2^2$$




$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 \\ 2x_2 \end{bmatrix}$$

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

例2：鞍点


$$f(\mathbf{x}) = x_1^2 - x_2^2$$



$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 \\ -2x_2 \end{bmatrix}$$

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}$$

例3：必要非充分举例



$$f(x) = x^3$$

$$\nabla f(x) = 3x^2$$

$$\nabla^2 f(x) = 6x$$

如果进一步满足 x^* 邻域内的所有点的 $\nabla^2 f(x) \geq 0$ ，则 $\nabla f(x^*) = 0$ 且 $\nabla^2 f(x^*) \geq 0$ 是 x^* 是极小值的充分条件。（应用不方便！）

二阶极小值条件（充分条件）

$$f(\mathbf{x} + \Delta\mathbf{x}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^T \Delta\mathbf{x} + \frac{1}{2} \Delta\mathbf{x}^T \nabla^2 f(\mathbf{x}) \Delta\mathbf{x} + O(\|\Delta\mathbf{x}\|^2)$$

$$\nabla f(\mathbf{x}^*) = \mathbf{0}$$


$$\nabla^2 f(\mathbf{x}^*) > 0$$

“>” 正定 \Rightarrow 严格局部极小值

“<” 负定 \Rightarrow 严格局部极大值

“=” 需检验更高阶导数项

例4 充分非必要举例



$$\nabla f(0) = 0$$

$$\nabla^2 f(0) = 0$$

小结

无约束极小值问题的最优性条件

■ 一阶必要条件：（局部极小值/局部极大值）

$$\nabla f(x^*)=0$$

■ 二阶必要条件：（局部极小值）

$$\nabla f(x^*)=0 \text{ 且 } \nabla^2 f(x^*) \geq 0$$

■ 二阶充分条件：（严格局部极小值）

$$\nabla f(x^*)=0 \text{ 且 } \nabla^2 f(x^*) > 0$$

非线性规划的解析解

➤ 非线性规划问题及其数学模型

➤ 非线性规划解析解法

□ 无约束极值问题

- 一阶条件
- 二阶条件

□ 有约束极值问题:

- 等式约束
- 不等式约束 (**Kuhn-Tucker**条件)
- 一般约束

➤ 凸规划

等式约束极值问题

$$\begin{array}{ll}\min & f(\mathbf{x}) \\ \text{s.t.} & h_i(\mathbf{x}) = 0 \quad i = 1, 2, \dots, m \\ & \mathbf{x} \in R^n\end{array}$$

$$\begin{array}{ll}\min & f(\mathbf{x}) \\ \text{s.t.} & \mathbf{h}(\mathbf{x}) = 0 \\ & \mathbf{x} \in R^n\end{array} \quad \mathbf{h}(\mathbf{x}) \triangleq \begin{bmatrix} h_1(\mathbf{x}) \\ \vdots \\ h_m(\mathbf{x}) \end{bmatrix}$$

Lagrange函数法

定义Lagrange函数

$$\min L(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) + \boldsymbol{\lambda}^T \mathbf{h}(\mathbf{x}) = f(\mathbf{x}) + \sum_{i=1}^m \lambda_i h_i(\mathbf{x})$$

$$\boldsymbol{\lambda} = [\lambda_1 \quad \lambda_2 \quad \cdots \quad \lambda_m]^T$$

求无约束极值问题:

$$\left. \frac{\partial L(\mathbf{x}, \boldsymbol{\lambda})}{\partial \mathbf{x}} \right|_{\mathbf{x}^*} = \mathbf{0} \quad \longrightarrow \quad \nabla f(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i \nabla h_i(\mathbf{x}^*) = \mathbf{0}$$

$$\left. \frac{\partial L(\mathbf{x}, \boldsymbol{\lambda})}{\partial \lambda} \right|_{\boldsymbol{\lambda}^*} = \mathbf{0} \quad \longrightarrow \quad h_i(\mathbf{x}^*) = 0 \quad i = 1, 2, \dots, m$$

非线性规划的解析解

➤ 非线性规划问题及其数学模型

➤ 非线性规划解析解法

□ 无约束极值问题

- 一阶条件
- 二阶条件

□ 有约束极值问题:

- 等式约束
- 不等式约束 (Kuhn-Tucker条件)
- 一般约束

➤ 凸规划

不等式约束极值问题

$$\min f(\mathbf{x})$$

$$\text{s.t.} \quad g_j(\mathbf{x}) \geq 0 \quad j = 1, 2, \dots, l$$

$$\mathbf{x} \in R^n$$

思考：能否如线性规划化为等式约束的问题？

求解思路

■ 直观思想：邻域内不存在可行的更优解

➤ 不存在同时满足以下两个条件的方向

- 可行点的可行方向
- 目标函数的下降方向

➤ 最优性条件

- **Fritz John**条件
- **Kuhn-Tucker**条件

可行方向

可行点 $\mathbf{x}^{(0)}$ 的可行方向 \mathbf{p} 是 $\mathbf{x}^{(0)}$ 沿 \mathbf{p} 方向移动无限小步后仍在可行域 R 内的方向（约束函数值增大方向），数学上可表述为：

$\exists \lambda_0 > 0$ ，对于 $\forall \lambda \in (0, \lambda_0]$ ，有：

$$\mathbf{x}^{(0)} + \lambda \mathbf{p} \in R, \quad R = \{\mathbf{x} \mid g_j(\mathbf{x}) \geq 0, j = 1, 2, \dots, l\}$$

即 $g_j(\mathbf{x}^{(0)} + \lambda \mathbf{p}) \geq 0 \quad j = 1, 2, \dots, l$

思考：可否直接用 $\exists \lambda > 0$ ，满足所有 $g_j(\mathbf{x}^{(0)} + \lambda \mathbf{p}) \geq 0$ 定义？

可行方向判别条件

$$\nabla g_j(\mathbf{x}^{(0)})^T \mathbf{p} > 0 \quad \forall j \in J(\mathbf{x}^{(0)}) \quad J(\mathbf{x}^{(0)}) = \{j \mid g_j(\mathbf{x}^{(0)}) = 0, j = 1, 2, \dots, l\}$$

起作用约束集合

证明： 根据Taylor公式，有

$$g_j(\mathbf{x}^{(0)} + \lambda \mathbf{p}) = g_j(\mathbf{x}^{(0)}) + \lambda \nabla g_j(\mathbf{x}^{(0)})^T \mathbf{p} + O(\lambda) \quad \|\mathbf{p}\| = 1$$

当 λ 足够小时，如果 $j \notin J$ ，假设 $g_j(\mathbf{x})$ 连续，有

$$g_j(\mathbf{x}^{(0)} + \lambda \mathbf{p}) \geq 0$$

如果， $j \in J$ ，当 $\nabla g_j(\mathbf{x}^{(0)})^T \mathbf{p} > 0$ 时，也有

$$g_j(\mathbf{x}^{(0)} + \lambda \mathbf{p}) \geq 0$$

几何含义：与所有起作用约束梯度方向一致，使 $g_j(\mathbf{x}) \geq 0$

下降方向

定义：令目标函数值 $f(\mathbf{x}^{(0)})$ 下降的方向，满足

$\exists \lambda_0 > 0$ ，对于 $\forall \lambda \in (0, \lambda_0]$ ，有 $f(\mathbf{x}^{(0)} + \lambda \mathbf{p}) < f(\mathbf{x}^{(0)})$

判别条件： $\nabla f(\mathbf{x}^{(0)})^T \mathbf{p} < 0$

证明：Taylor公式

$$f(\mathbf{x}^{(0)} + \lambda \mathbf{p}) = f(\mathbf{x}^{(0)}) + \lambda \nabla f(\mathbf{x}^{(0)})^T \mathbf{p} + O(\lambda)$$

几何含义：与目标函数负梯度方向一致

局部极小值存在的直观条件


不存在可行下降方向 \mathbf{p} ，即不存在同时满足下面两类不等式的方向。

$$\nabla f(\mathbf{x}^*)^T \mathbf{P} < 0$$


$$-\nabla g_j(\mathbf{x}^*)^T \mathbf{P} < 0 \quad j \in J(\mathbf{x}^*) \quad J \text{为起作用约束集合}$$

► 几何含义： \mathbf{p} 与上述梯度方向均成钝角

图示1：有可行下降方向



图示2：无可行下降方向



Gordan引理

➤ \mathbf{a}_j 为一组已知向量，不存在向量 \mathbf{p} ，使

$$\mathbf{a}_j^T \mathbf{p} < 0 \quad j = 1, 2, \dots, l$$

同时成立的充要条件：

存在不全为零的非负实数 $\mu_j \geq 0$ ，使

$$\sum_{j=1}^l \mu_j \mathbf{a}_j = \mathbf{0} \quad \text{正线性相关 (positive linear dependence)}$$

几何含义： \mathbf{a}_j 不可能分布在任何超平面的同一侧

正线性相关的性质

正线性相关： 存在不全为零的非负实数 $\mu_j \geq 0$ ，使

$$\sum_{j=1}^l \mu_j \mathbf{a}_j = \mathbf{0}$$

性质1：正线性相关的要求比线性相关更强。

正线性相关 \Rightarrow 线性相关。

性质2、正线性相关与负线性相关等价。

性质3：若部分 \mathbf{a}_j 正线性相关，则所有 \mathbf{a}_j 正线性相关。

Fritz John条件

➤ 若 \mathbf{x}^* 是局部极小点，则存在不全为零的非负实数 $\mu_j \geq 0$ ， $j \in J(\mathbf{x}^*)$ ，使

$$\mu_0 \nabla f(\mathbf{x}^*) - \sum_{j \in J} \mu_j \nabla g_j(\mathbf{x}^*) = \mathbf{0}$$

思考：Fritz John条件为什么不是极小点的充分条件？

缺点：需要事先确定起作用约束集

Fritz John定理

➤ 若 \mathbf{x}^* 是局部极小点，存在不全为零的非负实 $\mu_j \geq 0$ ， $j=1,2,\dots,l$ ，使

Fritz John条件

$$\left\{ \begin{array}{ll} \mu_0 \nabla f(\mathbf{x}^*) - \sum_{j=1}^l \mu_j \nabla g_j(\mathbf{x}^*) = \mathbf{0} & \text{Lagrange函数驻点条件} \\ \mu_j g_j(\mathbf{x}^*) = 0 & j = 1, 2, \dots, l \quad \text{互补松弛条件} \\ \mu_j \geq 0 & j = 0, 1, \dots, l \quad \text{强非负条件} \end{array} \right.$$

$\sum_{j=0}^l \mu_j \neq 0$

上述条件隐含了如下事实：

$$j \notin J(\mathbf{x}^*) \Rightarrow g_j(\mathbf{x}^*) > 0 \Rightarrow \mu_j = 0$$

Kuhn-Tucker定理

➤ 若 \mathbf{x}^* 是局部极小点，起作用约束的 $\nabla g_j(\mathbf{x}^*)$ 线性无关[约束规格(*constraint qualification*)]，则下列Kuhn-Tucker条件成立：

Kuhn-Tucker条件

$$\left\{ \begin{array}{ll} \nabla f(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0} & \text{Lagrange函数驻点条件} \\ \mu_j^* g_j(\mathbf{x}^*) = 0 & j = 1, 2, \dots, l \quad \text{互补松弛条件} \\ \mu_j^* \geq 0 & j = 1, 2, \dots, l \quad \text{非负条件} \end{array} \right.$$

可全为0

Karush(1939)
Kuhn-Tucker (1951)

思考1：上述条件有什么含义？

思考2：多了约束规格，Kuhn-Tucker条件是否是极小点的必要条件？

KT条件的矩阵形式

$$\boldsymbol{\gamma}^* = \begin{bmatrix} \gamma_1^* \\ \gamma_2^* \\ \vdots \\ \gamma_m^* \end{bmatrix} \quad \boldsymbol{h}(\boldsymbol{x}) = \begin{bmatrix} h_1(\boldsymbol{x}) \\ h_2(\boldsymbol{x}) \\ \vdots \\ h_m(\boldsymbol{x}) \end{bmatrix} \quad \boldsymbol{\mu}^* = \begin{bmatrix} \mu_1^* \\ \mu_2^* \\ \vdots \\ \mu_l^* \end{bmatrix} \quad \boldsymbol{g}(\boldsymbol{x}) = \begin{bmatrix} g_1(\boldsymbol{x}) \\ g_2(\boldsymbol{x}) \\ \vdots \\ g_l(\boldsymbol{x}) \end{bmatrix}$$

$$\nabla \boldsymbol{h}(\boldsymbol{x}) = [\nabla h_1(\boldsymbol{x}) \quad \nabla h_2(\boldsymbol{x}) \quad \cdots \quad \nabla h_m(\boldsymbol{x})]$$
$$\nabla \boldsymbol{g}(\boldsymbol{x}) = [\nabla g_1(\boldsymbol{x}) \quad \nabla g_2(\boldsymbol{x}) \quad \cdots \quad \nabla g_l(\boldsymbol{x})] = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \frac{\partial g_2}{\partial x_1} & \cdots & \frac{\partial g_l}{\partial x_1} \\ \frac{\partial g_1}{\partial x_2} & \frac{\partial g_2}{\partial x_2} & \cdots & \frac{\partial g_l}{\partial x_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial g_1}{\partial x_n} & \frac{\partial g_2}{\partial x_n} & \cdots & \frac{\partial g_l}{\partial x_n} \end{bmatrix} = \left(\frac{\partial \boldsymbol{g}(\boldsymbol{x})}{\partial \boldsymbol{x}} \right)^T$$

梯度矩阵与雅可比矩阵是转置关系

KT条件的矩阵形式

$$\nabla f(\mathbf{x}^*) - \nabla g(\mathbf{x}^*)\boldsymbol{\mu}^* = \mathbf{0}$$

$$\boldsymbol{\mu}^{*T} \mathbf{g}(\mathbf{x}^*) = 0 \quad \text{注意: 互补松弛性条件包含} l \text{ 个等式!}$$

$$\boldsymbol{\mu}^* \geq 0$$

$$\text{diag}(\boldsymbol{\mu}^*)\mathbf{g}(\mathbf{x}^*) = \begin{bmatrix} \mu_1^* & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \mu_l^* \end{bmatrix} \begin{bmatrix} g_1^*(\mathbf{x}^*) \\ \vdots \\ g_l^*(\mathbf{x}^*) \end{bmatrix} = \begin{bmatrix} \mu_1^* g_1^*(\mathbf{x}^*) \\ \vdots \\ \mu_l^* g_l^*(\mathbf{x}^*) \end{bmatrix} = \mathbf{0}$$

$$\mathbf{g}(\mathbf{x}^*) \geq \mathbf{0} \quad \text{可行解条件}$$

举例

$$\min f(x_1, x_2) = (x_1 - 2)^2 + x_2^2$$

$$\text{s.t. } x_2 \leq x_1 + 2$$

$$x_2 \geq x_1^2 + 1$$

$$x_1 \geq 0 \quad x_2 \geq 0$$

目标函数、约束函数

$$f(\mathbf{x}) = (x_1 - 2)^2 + x_2^2$$

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2(x_1 - 2) \\ 2x_2 \end{bmatrix}$$

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} x_1 - x_2 + 2 \\ -x_1^2 + x_2 - 1 \\ x_1 \\ x_2 \end{bmatrix}$$

$$\nabla \mathbf{g}(\mathbf{x}) = \begin{bmatrix} 1 & -2x_1 & 1 & 0 \\ -1 & 1 & 0 & 1 \end{bmatrix}$$

KT条件的矩阵形式

$$\nabla f(\mathbf{x}^*) - \nabla h(\mathbf{x}^*)\gamma^* - \nabla g(\mathbf{x}^*)\boldsymbol{\mu}^* = \mathbf{0}$$

$$\longrightarrow \begin{bmatrix} 2(x_1 - 2) \\ 2x_2 \end{bmatrix} - \begin{bmatrix} 1 & -2x_1 & 1 & 0 \\ -1 & 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \\ \mu_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\mathbf{g}(\mathbf{x}^*)^T \boldsymbol{\mu}^* = 0$$

$$\longrightarrow \begin{bmatrix} x_1 - x_2 + 2 & -x_1^2 + x_2 - 1 & x_1 & x_2 \end{bmatrix} \begin{bmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \\ \mu_4 \end{bmatrix} = 0$$

$$\mathbf{g}(\mathbf{x}^*) \geq \mathbf{0} \quad \boldsymbol{\mu}^* \geq \mathbf{0}$$

KT条件的代数形式

$$2(x_1 - 2) - \mu_1 + 2\mu_2 x_1 - \mu_3 = 0$$

$$2x_2 + \mu_1 - \mu_2 - \mu_4 = 0$$

$$\mu_1(x_1 - x_2 + 2) = 0$$

$$\mu_2(-x_1^2 + x_2 - 1) = 0$$

$$\mu_3 x_1 = 0$$

$$\mu_4 x_2 = 0$$

6个变量、6个方程


$$\mu_j \geq 0 \quad j = 1, 2, 3, 4$$

$$x_2 \leq x_1 + 2 \quad x_1 \geq 0$$

$$x_2 \geq x_1^2 + 1 \quad x_2 \geq 0$$

不等式条件

图示



求解

观察可得: $\mu_1 = \mu_3 = \mu_4 = 0$

所以有: $(1 + \mu_2)x_1 - 2 = 0$

$$2x_2 - \mu_2 = 0$$

$$-x_1^2 + x_2 - 1 = 0$$

求解得: $\mu_2^* = 2.6219$ $x_1^* = 0.5536$ $x_2^* = 1.3064$

$$f(\mathbf{x}^*) = 3.7989$$

非线性规划的解析解

➤ 非线性规划问题及其数学模型

➤ 非线性规划解析解法

□ 无约束极值问题

- 一阶条件
- 二阶条件

□ 有约束极值问题:

- 等式约束
- 不等式约束 (Kuhn-Tucker条件)
- 一般约束

➤ 凸规划

一般约束极值问题

$$\min f(\mathbf{x})$$

$$\text{s.t.} \quad h_i(\mathbf{x}) = 0 \quad i = 1, 2, \dots, m$$

$$g_j(\mathbf{x}) \geq 0 \quad j = 1, 2, \dots, l$$

$$\mathbf{x} \in R^n$$

求解思路：化为不等式约束极值问题

等价不等式约束极值问题

$$\min f(\mathbf{x})$$

$$\text{s.t.} \quad h_i(\mathbf{x}) \geq 0 \quad i = 1, 2, \dots, m$$

$$-h_i(\mathbf{x}) \geq 0 \quad i = 1, 2, \dots, m$$

$$g_j(\mathbf{x}) \geq 0 \quad j = 1, 2, \dots, l$$

$$\mathbf{x} \in R^n$$

KT条件推导

➤ 根据Kuhn-Tucker条件，有

$$\nabla f(\mathbf{x}^*) - \sum_{i=1}^m \mu'_i{}^* \nabla h_i(\mathbf{x}^*) + \sum_{i=1}^m \mu''_i{}^* \nabla h_i(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0}$$



$$\nabla f(\mathbf{x}^*) - \sum_{i=1}^m (\mu'_i{}^* - \mu''_i{}^*) \nabla h_i(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0}$$



$$\nabla f(\mathbf{x}^*) - \sum_{i=1}^m \gamma_i^* \nabla h_i(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0}$$

$$\mu'_i{}^* \geq 0 \quad \mu''_i{}^* \geq 0 \quad \longrightarrow \quad \gamma_i^* \text{无符号约束} \quad i = 1, 2, \dots, m$$

一般约束下的KT条件

- 若 \mathbf{x}^* 是局部极小点，等式约束梯度 $\nabla h_i(\mathbf{x}^*)$ 和起作用约束梯度 $\nabla g_j(\mathbf{x}^*)$ 线性无关，则下列条件成立：

$$\nabla f(\mathbf{x}^*) - \sum_{i=1}^m \gamma_i^* \nabla h_i(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0} \quad \text{Lagrange驻点条件}$$

$$\mu_j^* g_j(\mathbf{x}^*) = 0 \quad j = 1, 2, \dots, l \quad \text{互补松弛条件}$$

$$\mu_j^* \geq 0 \quad j = 1, 2, \dots, l \quad \text{非负条件}$$

广义Lagrange函数法

定义Lagrange函数

$$L(\mathbf{x}, \boldsymbol{\gamma}, \boldsymbol{\mu}) = f(\mathbf{x}) - \sum_{i=1}^m \gamma_i h_i(\mathbf{x}) - \sum_{j=1}^l \mu_j g_j(\mathbf{x})$$

γ_i^* 和 μ_j^* 称为广义Lagrange乘子

类似无约束极值问题，得到：

$$\nabla f(\mathbf{x}^*) - \sum_{i=1}^m \gamma_i^* \nabla h_i(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0}$$

Lagrange驻点条件

$$\mu_j^* g_j(\mathbf{x}^*) = 0 \quad j = 1, 2, \dots, l$$

互补松弛条件

$$\mu_j^* \geq 0 \quad j = 1, 2, \dots, l$$

非负条件

$$h_i(\mathbf{x}^*) = 0 \quad i = 1, 2, \dots, m$$

可行性条件

$$g_j(\mathbf{x}^*) \geq 0 \quad j = 1, 2, \dots, l$$

KT条件的矩阵形式

$$\nabla f(\mathbf{x}^*) - \nabla h(\mathbf{x}^*)\gamma^* - \nabla g(\mathbf{x}^*)\mu^* = \mathbf{0} \quad \text{Lagrange驻点条件}$$

$$\mu^{*T} g(\mathbf{x}^*) = 0 \quad \text{或} \quad \text{diag}(\mu^*)g(\mathbf{x}^*) = \mathbf{0} \quad \text{互补松弛条件}$$

$$\mu^* \geq 0$$

非负条件

$$\mu_j^* g_j(\mathbf{x}^*) = 0$$

$$j = 1, 2, \dots, l$$

$$h(\mathbf{x}^*) = \mathbf{0}$$

可行性条件

$$g(\mathbf{x}^*) \geq \mathbf{0}$$

非线性规划的解析解

➤ 非线性规划问题及其数学模型

➤ 非线性规划解析解法

□ 无约束极值问题

- 一阶条件
- 二阶条件

□ 有约束极值问题:

- 等式约束
- 不等式约束 (**Kuhn-Tucker**条件)
- 一般约束

➤ 凸规划

凸规划

$$\min f(\mathbf{x}) \quad \text{凸函数}$$

$$\text{s.t. } h_i(\mathbf{x}) = 0 \quad i = 1, 2, \dots, m \quad \text{线性函数}$$

$$g_j(\mathbf{x}) \geq 0 \quad j = 1, 2, \dots, l \quad \text{凹函数}$$

$$\mathbf{x} \in R^n$$

凸函数与凹函数

- 凸函数为满足下列条件的函数：


$$f[\lambda \mathbf{x}_1 + (1-\lambda)\mathbf{x}_2] \leq \lambda f(\mathbf{x}_1) + (1-\lambda)f(\mathbf{x}_2) \quad 0 < \lambda < 1 \quad \mathbf{x}_1, \mathbf{x}_2 \in R^n$$

- “<”：严格凸函数
- “≥”：凹函数
- “>”：严格凹函数


注意：线性函数既是凸函数，又是凹函数，所以线性规划是凸规划。

凸函数和凹函数图示


凸函数



凹函数



非凸非凹函数



凸函数判定条件（充要条件）

- 一阶条件

$$\forall \mathbf{x}_1, \mathbf{x}_2 \in R^n \quad \text{恒有} \quad f(\mathbf{x}_2) \geq f(\mathbf{x}_1) + \nabla f(\mathbf{x}_1)^T (\mathbf{x}_2 - \mathbf{x}_1)$$

几何意义：任何一点的切线在凸函数曲线的下方

- 二阶条件

$$\forall \mathbf{x} \in R^n \quad \text{恒有} \quad \nabla^2 f(\mathbf{x}) \geq 0$$

几何意义：函数曲线向上弯曲

- “>”：严格凸函数
- “≤”：凹函数
- “<”：严格凹函数
- “=”：线性函数

二次函数为凸函数的充要条件

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{H} \mathbf{x} + \mathbf{c}^T \mathbf{x} + r \quad \mathbf{H} \text{为对称矩阵}$$

$$\nabla f(\mathbf{x}) = \mathbf{H} \mathbf{x} + \mathbf{c}$$

$$\nabla^2 f(\mathbf{X}) = \mathbf{H} \geq 0 \quad \mathbf{H} \text{为半正定矩阵}$$

凸函数的性质

- 凸函数非负线性组合仍为凸函数

$$\gamma_1 f_1(\mathbf{x}) + \gamma_2 f_2(\mathbf{x}) \quad \gamma_i \geq 0$$

- 若 $f(\mathbf{x})$ 是定义在凸集 R_C 上的凸函数，则其 β 水平集 S_β 为凸集。

$$S_\beta = \{\mathbf{x} \mid f(\mathbf{x}) \leq \beta, \mathbf{x} \in R_C\} \quad \beta\text{水平集}$$

- 对于凸函数 $f(\mathbf{x})$ ，若存在 $\mathbf{x}^* \in R^n$ 满足

$$\nabla f(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) \geq 0 \quad \forall \mathbf{x} \in R^n \quad \text{充要条件!}$$

则 \mathbf{x}^* 为 $f(\mathbf{x})$ 的全局最小点。

$$f(\mathbf{x}_2) \geq f(\mathbf{x}_1) + \nabla f(\mathbf{x}_1)^T (\mathbf{x}_2 - \mathbf{x}_1)$$

推论1：对于凸目标函数， $\nabla f(\mathbf{x}^*)=0$ 是 \mathbf{x}^* 为极小值的充要条件。

推论2：对于凸目标函数，局部极小点也是全局最小点。

凸集性质

- 凸规划的可行域为凸集

$$h_i(\mathbf{x}) = 0 \quad -g_j(\mathbf{x}) \leq 0$$

各约束的0水平集为凸集

凸集的交集为凸集

- 如果最优解存在，最优解集合也为凸集

$$f[\lambda \mathbf{x}_1^* + (1-\lambda)\mathbf{x}_2^*] \leq \lambda f(\mathbf{x}_1^*) + (1-\lambda)f(\mathbf{x}_2^*) = f(\mathbf{x}_1^*) = f(\mathbf{x}_2^*) \quad 0 < \lambda < 1$$

➡ $f[\lambda \mathbf{x}_1^* + (1-\lambda)\mathbf{x}_2^*] = f(\mathbf{x}_1^*) = f(\mathbf{x}_2^*)$ 最优解的连线段均为最优解

推论：线性规划问题的最优解集为所有最优顶点构成的多边形。（归纳法证）

$$\mathbf{x}^* = \sum_{i=1}^r a_i \mathbf{x}_i^* \quad \sum_{i=1}^r a_i = 1 \quad 0 \leq a_i \leq 1 \quad i = 1, \dots, r$$

凸规划性质

- 任何局部极值解也是全局最优解 （目标函数为凸函数）

局部极小点和全局最小点连线的目标函数值相同

- 若目标函数为严格凸函数，则如果全局最优解存在，必为唯一全局最优解。（反证法）

$$f[\lambda \mathbf{x}_1^* + (1-\lambda)\mathbf{x}_2^*] < \lambda f(\mathbf{x}_1^*) + (1-\lambda)f(\mathbf{x}_2^*) = f(\mathbf{x}_1^*) = f(\mathbf{x}_2^*)$$

最优解的唯一性为数值解法提供了方便。

- 凸规划下的KT条件为最优解的充要条件

KT条件的充分性证明

$$\nabla f(\mathbf{x}^*) - \sum_{i=1}^m \gamma_i^* \nabla h_i(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = 0 \quad \mu_j^* g_j(\mathbf{x}^*) = 0 \quad \mu_j^* \geq 0$$

$$\begin{aligned} f(\mathbf{x}) \text{ 是凸函数} &\Rightarrow f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) \\ &= f(\mathbf{x}^*) + \sum_{i=1}^m \gamma_i^* \nabla h_i(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) + \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) \end{aligned}$$

$$h_i(\mathbf{x}) \text{ 线性函数且 } h_i(\mathbf{x}) = 0 \Rightarrow \nabla h_i(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) = h_i(\mathbf{x}) - h_i(\mathbf{x}^*) = 0$$

$$g_j(\mathbf{x}) \text{ 是凹函数} \Rightarrow \nabla g_j(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) \geq g_j(\mathbf{x}) - g_j(\mathbf{x}^*)$$

根据互补松弛性条件 $\mu_j^* g_j(\mathbf{x}^*) = 0$ 且 $g_j(\mathbf{x}) \geq 0$ ，有

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \sum_{j=1}^l \mu_j^* [g_j(\mathbf{x}) - g_j(\mathbf{x}^*)] = f(\mathbf{x}^*) + \sum_{j=1}^l \mu_j^* g_j(\mathbf{x}) \geq f(\mathbf{x}^*)$$

举例


$$\min f(x_1, x_2) = (x_1 - 2)^2 + x_2^2$$

$$\text{s.t. } x_2 \leq x_1 + 2$$

$$x_2 \geq x_1^2 + 1$$

$$x_1 \geq 0$$

$$x_2 \geq 0$$



凸规划判断

$$f(\mathbf{x}) = (x_1 - 2)^2 + x_2^2 \Rightarrow \nabla f(\mathbf{x}) = \begin{bmatrix} 2(x_1 - 2) \\ 2x_2 \end{bmatrix} \Rightarrow \nabla^2 f(\mathbf{x}) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} > 0$$

$$g_1(\mathbf{x}) = x_1 - x_2 + 2 \Rightarrow \nabla g_1(\mathbf{x}) = \begin{bmatrix} 1 \\ -1 \end{bmatrix} \Rightarrow \nabla^2 g_1(\mathbf{x}) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$$

$$g_2(\mathbf{x}) = -x_1^2 + x_2 - 1 \Rightarrow \nabla g_2(\mathbf{x}) = \begin{bmatrix} -2x_1 \\ 1 \end{bmatrix} \Rightarrow \nabla^2 g_2(\mathbf{x}) = \begin{bmatrix} -2 & 0 \\ 0 & 0 \end{bmatrix} \leq 0$$

$$g_3(\mathbf{x}) = x_1 \Rightarrow \nabla g_3(\mathbf{x}) = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \Rightarrow \nabla^2 g_3(\mathbf{x}) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$$

$$g_4(\mathbf{x}) = x_2 \Rightarrow \nabla g_4(\mathbf{x}) = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \Rightarrow \nabla^2 g_4(\mathbf{x}) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$$