

第六章 非线性规划


➤ 非线性规划数值解法

□ 无约束极值问题

- 下降迭代法

□ 有约束极值问题

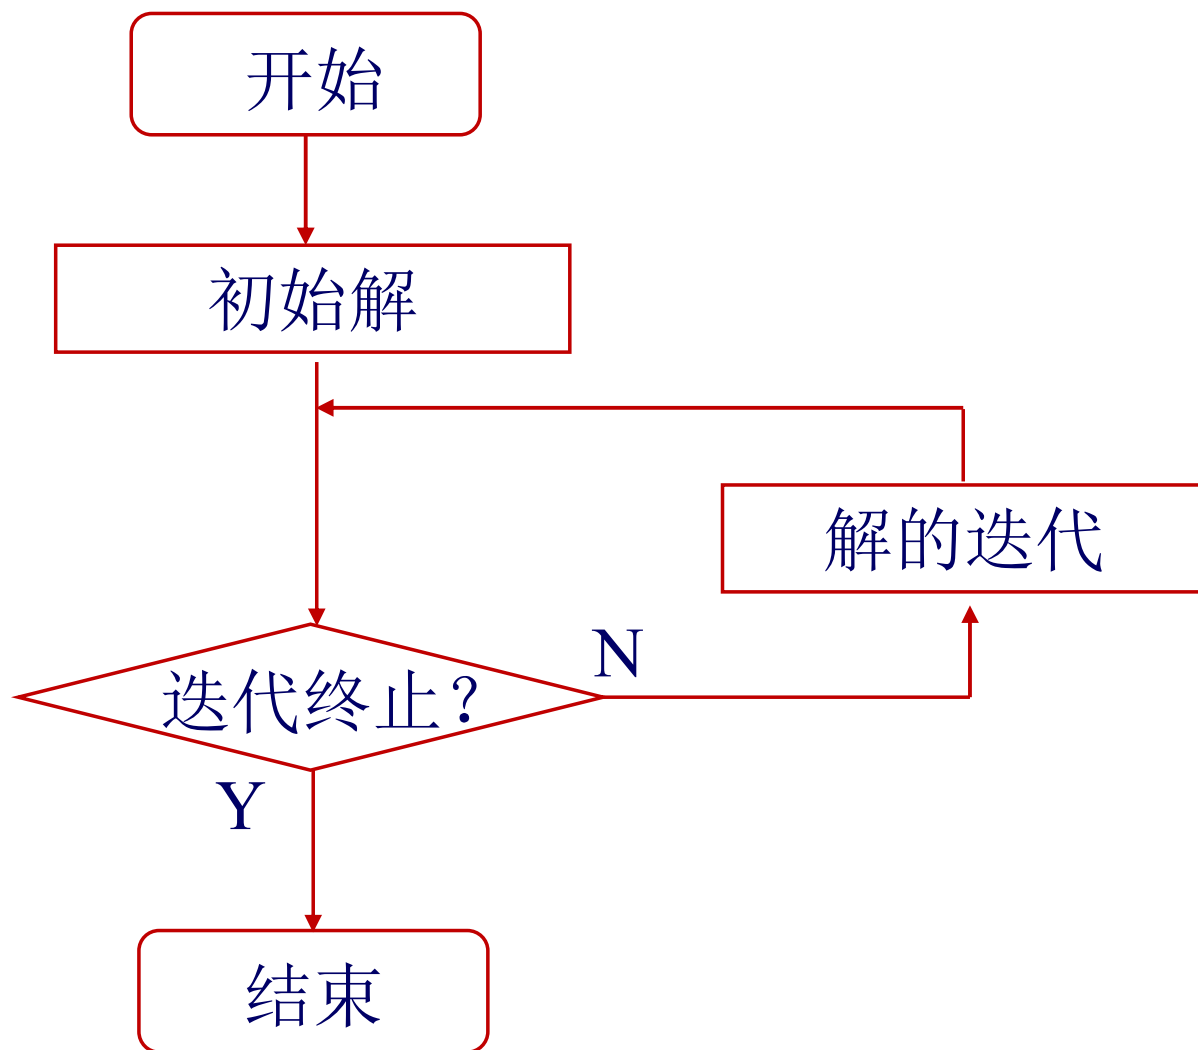
- 可行方向法
- 制约函数法
- 逐次逼近法



数值求解的一般思路

- 思想
 - 迭代法
- 方法类型
 - 基于梯度的方法
 - 非梯度的方法（直接法、启发式方法）
- 问题种类
 - 无约束极值问题
 - 有约束极值问题

数值解法的流程图



下降迭代法

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)} \quad \Rightarrow \quad f(\mathbf{x}^{(k+1)}) < f(\mathbf{x}^{(k)})$$

➤ 迭代方向

■ 基于梯度方法

- 最速下降法

- 牛顿法

- 拟牛顿法

- 共轭梯度法

■ 直接法

➤ 步长选择（一维搜索）

- 基于梯度法

- 直接法

➤ 迭代终止准则

最速下降法

■ 设计思想：使目标函数值下降

目标函数值： $f(\mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)}) = f(\mathbf{x}^{(k)}) + \lambda_k \nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)} + O(\lambda_k)$

可选方向： $\nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)} = \|\nabla f(\mathbf{x}^{(k)})\| \|\mathbf{p}^{(k)}\| \cos \theta < 0$ （方向导数）

下降最快方向： $\mathbf{p}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$ 负梯度方向

性质：最优步长时 $\nabla f(\mathbf{x}^{(k+1)}) \perp \nabla f(\mathbf{x}^{(k)})$

优点：计算量小。

缺点：“之”字迭代路径，接近极值点时尤为严重。

应用场合：迭代前期。

极小值点附近的等值面

$$f(\mathbf{x}) = f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^*)^T \nabla^2 f(\mathbf{x}^*) (\mathbf{x} - \mathbf{x}^*) + O(\|\mathbf{x} - \mathbf{x}^*\|^2)$$

极值点: $\nabla f(\mathbf{x}^*) = 0 \longrightarrow f(\mathbf{x}) = f(\mathbf{x}^*) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^*)^T \nabla^2 f(\mathbf{x}^*) (\mathbf{x} - \mathbf{x}^*) + O(\|\mathbf{x} - \mathbf{x}^*\|^2)$

极值点附近等值面 $\longrightarrow f(\mathbf{x}) = c \approx f(\mathbf{x}^*) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^*)^T \nabla^2 f(\mathbf{x}^*) (\mathbf{x} - \mathbf{x}^*)$
 $\mathbf{x}^{(k)} \in N(\mathbf{x}^*, \varepsilon) \quad f(\mathbf{x}) = c$

$$\longrightarrow (\mathbf{x} - \mathbf{x}^*)^T \nabla^2 f(\mathbf{x}^*) (\mathbf{x} - \mathbf{x}^*) \approx c' = 2[c - f(\mathbf{x}^*)]$$

严格极小点: $\nabla^2 f(\mathbf{x}^*) > 0 \longrightarrow \mathbf{x}^*$ 为中心的椭球面

$\nabla^2 f(\mathbf{x}^*) \geq 0 \longrightarrow$ 椭球柱面 (降维椭球面) / 抛物面 / 平行超平面

牛顿法

$$\frac{d(k^T \mathbf{x})}{d\mathbf{x}} = \mathbf{k}$$

$$\frac{d\left(\frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x}\right)}{d\mathbf{x}} = \mathbf{A} \mathbf{x}$$

■ 设计思想：直接指向极值点。

$$f(\mathbf{x}) \approx f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(k)})^T \nabla^2 f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)})$$

两边对 \mathbf{x} 求导 $\longrightarrow \nabla f(\mathbf{x}) \approx \nabla f(\mathbf{x}^{(k)}) + \nabla^2 f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)})$

$\mathbf{x} = \mathbf{x}^*$ $\longrightarrow \nabla f(\mathbf{x}^*) = 0 \approx \nabla f(\mathbf{x}^{(k)}) + \nabla^2 f(\mathbf{x}^{(k)}) (\mathbf{x}^* - \mathbf{x}^{(k)})$

$\longrightarrow \mathbf{x}^* \approx \mathbf{x}^{(k)} - [\nabla^2 f(\mathbf{x}^{(k)})]^{-1} \nabla f(\mathbf{x}^{(k)})$

$\longrightarrow \mathbf{p}^{(k)} = -[\nabla^2 f(\mathbf{x}^{(k)})]^{-1} \nabla f(\mathbf{x}^{(k)})$ 迭代方向

优点：极值点附近收敛速率快。

缺点：计算量大，需要求二阶导数和矩阵逆。

远离极值点时，牛顿方向不一定是下降方向。

应用场合：二次目标函数或极值点附近，通常需采用进一步修正。

Levenberg-Marquardt修正

- 设计思想：使 $\nabla^2 f(\mathbf{x}^{(k)})$ 变为正定矩阵，保证牛顿法方向为下降方向

L-M修正方向：
$$\mathbf{p}^{(k)} = -[\nabla^2 f(\mathbf{x}^{(k)}) + \mu_k \mathbf{I}]^{-1} \nabla f(\mathbf{x}^{(k)})$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - [\nabla^2 f(\mathbf{x}^{(k)}) + \mu_k \mathbf{I}]^{-1} \nabla f(\mathbf{x}^{(k)})$$

$\mu_k > |\lambda_{\min}^-|$ λ_{\min}^- 为 $\nabla^2 f(\mathbf{x}^{(k)})$ 最小负特征值

$\mu \rightarrow 0$: 牛顿法

$\mu \rightarrow \infty$: 最速下降法

如果不求特征值，可以从较小的 μ 值试探

拟牛顿条件

- 设计思想：避免求二阶导数和逆。

$$f(\mathbf{x}) \approx f(\mathbf{x}^{(k+1)}) + \nabla f(\mathbf{x}^{(k+1)})^T (\mathbf{x} - \mathbf{x}^{(k+1)}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(k+1)})^T \nabla^2 f(\mathbf{x}^{(k+1)}) (\mathbf{x} - \mathbf{x}^{(k+1)})$$

两边对 \mathbf{x} 求导



$$\nabla f(\mathbf{x}) \approx \nabla f(\mathbf{x}^{(k+1)}) + \nabla^2 f(\mathbf{x}^{(k+1)}) (\mathbf{x} - \mathbf{x}^{(k+1)})$$

在 $\mathbf{x}^{(k+1)}$ 展开

$\mathbf{x} = \mathbf{x}^{(k)}$



$$\nabla f(\mathbf{x}^{(k)}) \approx \nabla f(\mathbf{x}^{(k+1)}) + \nabla^2 f(\mathbf{x}^{(k+1)}) (\mathbf{x}^{(k)} - \mathbf{x}^{(k+1)})$$



$$\nabla f(\mathbf{x}^{(k)}) - \nabla f(\mathbf{x}^{(k+1)}) \approx \nabla^2 f(\mathbf{x}^{(k+1)}) (\mathbf{x}^{(k)} - \mathbf{x}^{(k+1)})$$



$$\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)} \approx [\nabla^2 f(\mathbf{x}^{(k+1)})]^{-1} [\nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})]$$

$$\boldsymbol{\delta}_k \triangleq \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$$

$$\mathbf{H}_k \approx [\nabla^2 f(\mathbf{x}^{(k)})]^{-1}$$

$$\boldsymbol{\gamma}_k \triangleq \nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})$$



$$\boldsymbol{\delta}_k = \mathbf{H}_{k+1} \boldsymbol{\gamma}_k$$

拟牛顿条件

逆Hesse矩阵求解（变尺度法）

➤ 目标：给出一种求取 H_k 的方法

由Davidon提出，Fletcher和Powell改进，也称DFP算法。

迭代方向：
$$\mathbf{p}^{(k)} = -\mathbf{H}_k \nabla f(\mathbf{x}^{(k)})$$

$$\mathbf{H}_{k+1} = \mathbf{H}_k + \Delta \mathbf{H}_k \quad \mathbf{H}_1 = \mathbf{I}$$

$$\Delta \mathbf{H}_k = \frac{\boldsymbol{\delta}_k \boldsymbol{\delta}_k^T}{\boldsymbol{\delta}_k^T \boldsymbol{\gamma}_k} - \frac{\mathbf{H}_k \boldsymbol{\gamma}_k \boldsymbol{\gamma}_k^T \mathbf{H}_k}{\boldsymbol{\gamma}_k^T \mathbf{H}_k \boldsymbol{\gamma}_k}$$

$$\boldsymbol{\delta}_k \triangleq \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$$

$$\boldsymbol{\gamma}_k \triangleq \nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})$$

可以证明：1、 \mathbf{H}_k 满足拟牛顿条件，为Hesse矩阵的逆。

2、当目标函数为正定二次函数时，可经有限步迭代收敛于极值（二次终止性）。为什么不是1步？

共轭梯度法

- 共轭方向定义：若 A 正定，且 $p^{(1)}$ 和 $p^{(2)}$ 满足 $p^{(1)T} A p^{(2)} = 0$ ，则 $p^{(1)}$ 、 $p^{(2)}$ 关于 A 共轭。（共轭是正交概念的推广）

\Rightarrow 若 $p^{(1)}$ 、 $p^{(2)}$ 称关于 A 共轭，则 $p^{(1)}$ 和 $A p^{(2)}$ 正交。


- 二次凸函数： $f(x) = 1/2 * (x - x^*)^T A (x - x^*)$

➡ $\nabla f(x) = A(x - x^*)$

$p^{(1)} := p_t$ ($x^{(2)}$ 点切线方向)

$p^{(2)} := -(x^{(2)} - x^*)$

➡ $p^{(1)T} A p^{(2)} = -p_t^T \nabla f(x^{(2)}) = 0$



Fletcher-Reeves法

- 设计思想：利用梯度构造共轭方向进行迭代

迭代方向： $\mathbf{p}^{(k+1)} = -\nabla f(\mathbf{x}^{(k+1)}) + \beta_k \mathbf{p}^{(k)}$ $\mathbf{p}^{(1)} = -\nabla f(\mathbf{x}^{(1)})$

将 $\mathbf{p}^{(k+1)}$ 代入 共轭方程

$$\mathbf{p}^{(k)T} \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{p}^{(k+1)} = 0$$

→
$$-\mathbf{p}^{(k)T} \nabla^2 f(\mathbf{x}^{(k)}) \nabla f(\mathbf{x}^{(k+1)}) + \beta_k \mathbf{p}^{(k)T} \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{p}^{(k)} = 0$$

→
$$\beta_k = \frac{\mathbf{p}^{(k)T} \nabla^2 f(\mathbf{x}^{(k)}) \nabla f(\mathbf{x}^{(k+1)})}{\mathbf{p}^{(k)T} \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{p}^{(k)}}$$

Fletcher-Reeves法

注意：n>2时， $\mathbf{p}^{(1)}$ 的共轭方向不止1个， $-\nabla f(\mathbf{x}^{(2)}) + \beta_1 \mathbf{p}^{(1)}$ 未必指向 \mathbf{x}^*

共轭方向组

■ 共轭方向组定义：若 A 是 n 阶正定矩阵，且 $p^{(1)}, p^{(2)} \dots p^{(k)}$ 为 k 个关于 A 两两共轭的方向，则称这组方向关于 A 共轭。

■ 性质： $k \leq n$ ，则 A 的 k 个非零共轭方向线性无关。（反证法）

$$\sum_{i=1}^k \alpha_i p^{(i)} = 0 \quad \Rightarrow \quad \sum_{i=1}^k \alpha_i p^{(i)T} A p^{(j)} = \alpha_j p^{(j)T} A p^{(j)} = 0 \quad \Rightarrow \quad \alpha_j = 0$$

■ 定理：沿着 A 的 n 个非零共轭方向依次做一维最优步长搜索，则最多经过 n 步可找到二次凸函数的极小值。

$$\left. \begin{array}{l} \text{数学归纳法} \Rightarrow \nabla f(x^{(k+1)})^T p^{(j)} = 0 \\ \quad 1 \leq j \leq k \leq n \\ \nabla f(x^{(n+1)}) = \sum_{i=1}^n \alpha_i p^{(i)} \end{array} \right\} \Rightarrow \nabla f(x^{(n+1)})^T \left(\sum_{i=1}^n \alpha_i p^{(i)} \right) = 0 \Rightarrow \nabla f(x^{(n+1)}) = 0$$

等价公式

➤ 目标：避免求取二阶导数

共轭梯度法迭代方向：

$$\mathbf{p}^{(k+1)} = -\nabla f(\mathbf{x}^{(k+1)}) + \beta_k \mathbf{p}^{(k)}$$

Crowder-Wolfe公式：

$$\beta_k = \frac{\nabla f(\mathbf{x}^{(k+1)})^T [\nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})]}{\mathbf{p}^{(k)T} [\nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})]}$$

Polak-Ribiere公式：

$$\beta_k = \frac{\nabla f(\mathbf{x}^{(k+1)})^T [\nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})]}{\nabla f(\mathbf{x}^{(k)})^T \nabla f(\mathbf{x}^{(k)})}$$

Fletcher-Reeves公式：

$$\beta_k = \frac{\nabla f(\mathbf{x}^{(k+1)})^T \nabla f(\mathbf{x}^{(k+1)})}{\nabla f(\mathbf{x}^{(k)})^T \nabla f(\mathbf{x}^{(k)})}$$

下降迭代法

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)} \quad \Rightarrow \quad f(\mathbf{x}^{(k+1)}) < f(\mathbf{x}^{(k)})$$

- 迭代方向
 - 基于梯度方法
 - 最速下降法
 - 牛顿法
 - 拟牛顿法
 - 共轭梯度法
 - 直接法
- 步长选择（一维搜索）
 - 基于梯度法
 - 直接法
- 迭代终止准则

迭代步长

设计思想：沿给定方向搜索目标函数值最小的距离


$$\lambda_k = \arg \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})$$

- 基于梯度方法
- 直接法
 - **Fibonacci**斐波那契法
 - **0.618**法

基于梯度方法

目标: $\lambda_k = \arg \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})$

$$f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)}) = f(\mathbf{x}^{(k)}) + \lambda \nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)} + \frac{1}{2} \lambda^2 \mathbf{p}^{(k)T} \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{p}^{(k)} + O(\lambda^2)$$

极小值  $\frac{df(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})}{d\lambda} \approx \nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)} + \lambda \mathbf{p}^{(k)T} \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{p}^{(k)} = 0$



$$\lambda^* = \frac{-\nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)}}{\mathbf{p}^{(k)T} \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{p}^{(k)}}$$

- 特点:
- 1、解析解, 不需迭代
 - 2、需求Hesse矩阵
 - 3、 $\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)}$ 未必是极小值

最速下降法的性质


■ 性质：最优步长时 $\nabla f(\mathbf{x}^{(k+1)}) \perp \nabla f(\mathbf{x}^{(k)})$

■ 证明


$$\begin{aligned} & \frac{df(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})}{d\lambda} \\ &= \left(\frac{df(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})}{d(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})} \right)^T \frac{d(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})}{d\lambda} \\ &= \nabla f(\mathbf{x}^{(k+1)})^T \mathbf{p}^{(k)} \\ &= -\nabla f(\mathbf{x}^{(k+1)})^T \nabla f(\mathbf{x}^{(k)}) \\ &= 0 \end{aligned}$$

分数法

- 假设: $f(x)$ 在 $[a,b]$ 区间内单峰或无峰。假设是否合理?
- 特点: 取 $x_1, x'_1 \in (a, b)$, 将 $[a,b]$ 分为3个区间。则最小值 x^* 必定位于 x_1, x'_1 两点中目标函数值较小一点所在的两个相邻区间内。
- 算法思想: 将 x_1, x'_1 两点中目标函数值大的点作为新的边界, 不断缩小最优值所在区间的范围。




$$x^* \in [a, x'_1]$$



$$x^* \in [a, x_1]$$

搜索点选取

- 目标：计算量最小
- 方法：当前目标区的搜索点可直接用于下一次搜索



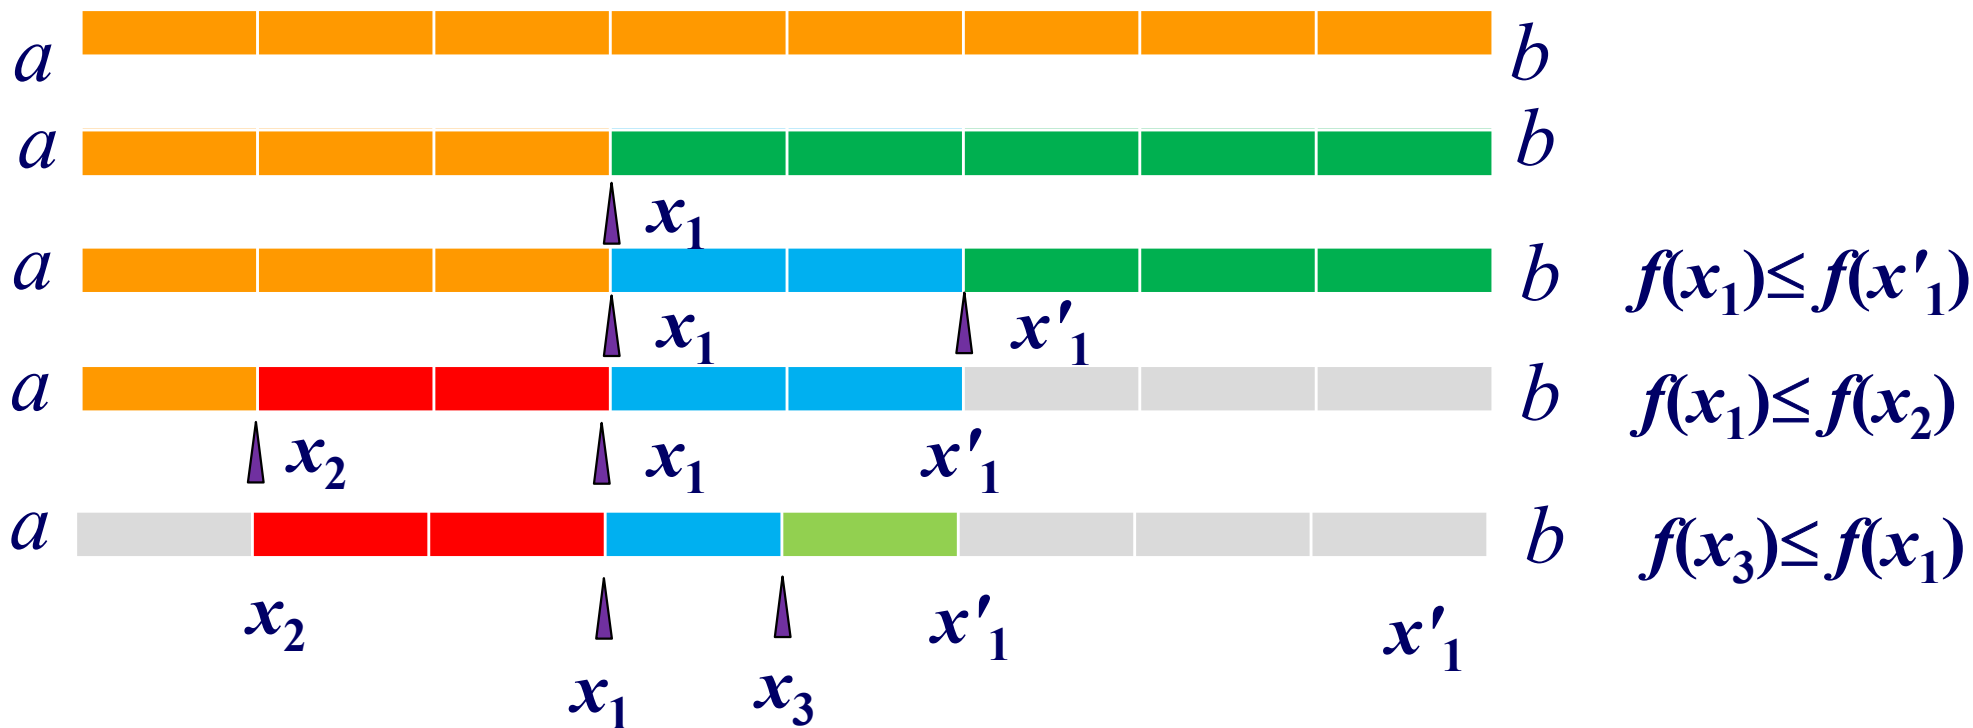
问题：如果单峰点是最大值会怎样？

斐波那契法


● Fibonacci数列

$$F_n = F_{n-1} + F_{n-2}, \quad n \geq 2 \quad F_0 = 1 \quad F_1 = 1$$

n	0	1	2	3	4	5
F _n	1	1	2	3	5	8



0.618法（黄金分割点法）



$$r*r=1-r \quad \longrightarrow \quad r^2+r-1=0 \quad \longrightarrow \quad r=0.618$$

可以证明： $\lim_{n \rightarrow \infty} \frac{F_{n-1}}{F_n} = r = 0.618$

下降迭代法

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)} \quad \Rightarrow \quad f(\mathbf{x}^{(k+1)}) < f(\mathbf{x}^{(k)})$$

- 迭代方向
 - 基于梯度方法
 - 最速下降法
 - 牛顿法
 - 拟牛顿法
 - 共轭梯度法
 - 直接法
- 步长选择（一维搜索）
 - 基于梯度法
 - 直接法
- 迭代终止准则

迭代终止准则

■ 迭代收敛准则

● 绝对误差准则

$$\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| \leq \varepsilon_1$$

$$|f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)})| \leq \varepsilon_2$$

● 相对误差准则

$$\frac{\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|}{\|\mathbf{x}^{(k)}\|} \leq \varepsilon_3$$

$$\frac{|f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)})|}{|f(\mathbf{x}^{(k)})|} \leq \varepsilon_4$$

■ 梯度模准则(first-order optimality measure)

$$\|\nabla f(\mathbf{x}^{(k)})\| \leq \varepsilon_5$$

$$\frac{\|\nabla f(\mathbf{x}^{(k)})\|}{\|\nabla f(\mathbf{x}^{(0)})\|} \leq \varepsilon_6$$

完整算法举例

- 1、设置初始点 $\mathbf{x}^{(1)}$ 、迭代终止阈值 ε , $k=1$;
- 2、如果 $\|\nabla f(\mathbf{x}^{(k)})\| \leq \varepsilon$, $\mathbf{x}^* = \mathbf{x}^{(k)}$, 迭代结束。
- 3、否则继续迭代

$$\mathbf{p}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$$

$$\lambda_k = \arg \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)}$$

$k \leftarrow k+1$, 返回第2步。

第六章 非线性规划

➤ 非线性规划数值解法

□ 无约束极值问题


● 下降迭代法

□ 有约束极值问题

● 可行方向法

● 制约函数法

● 逐次逼近法



约束极值问题的数值解

➤ 可行方向法

➤ Zoutendijk可行方向法

➤ 制约函数法

➤ 外点法

➤ 内点法

➤ 混合法

➤ 逐次逼近法（近似规划法）


➤ SLP (Sequential Linear Programming)

➤ SQP (Sequential Quadratic Programming)

Zoutendijk可行方向法

- 可行下降方向

$$\begin{cases} \nabla f(\mathbf{x}^{(k)})^T \mathbf{p} < 0 \\ -\nabla g_j(\mathbf{x}^{(k)})^T \mathbf{p} < 0 \end{cases} \quad j \in J \quad J \text{为起作用约束集合}$$


$$\begin{cases} \nabla f(\mathbf{x}^{(k)})^T \mathbf{p} < \eta \\ -\nabla g_j(\mathbf{x}^{(k)})^T \mathbf{p} < \eta \\ \eta < 0 \end{cases} \quad j \in J$$

$\mathbf{x}^{(k)}$ 为可行点

$\eta < 0$: \mathbf{p} 为 $\mathbf{x}^{(k)}$ 的可行下降方向

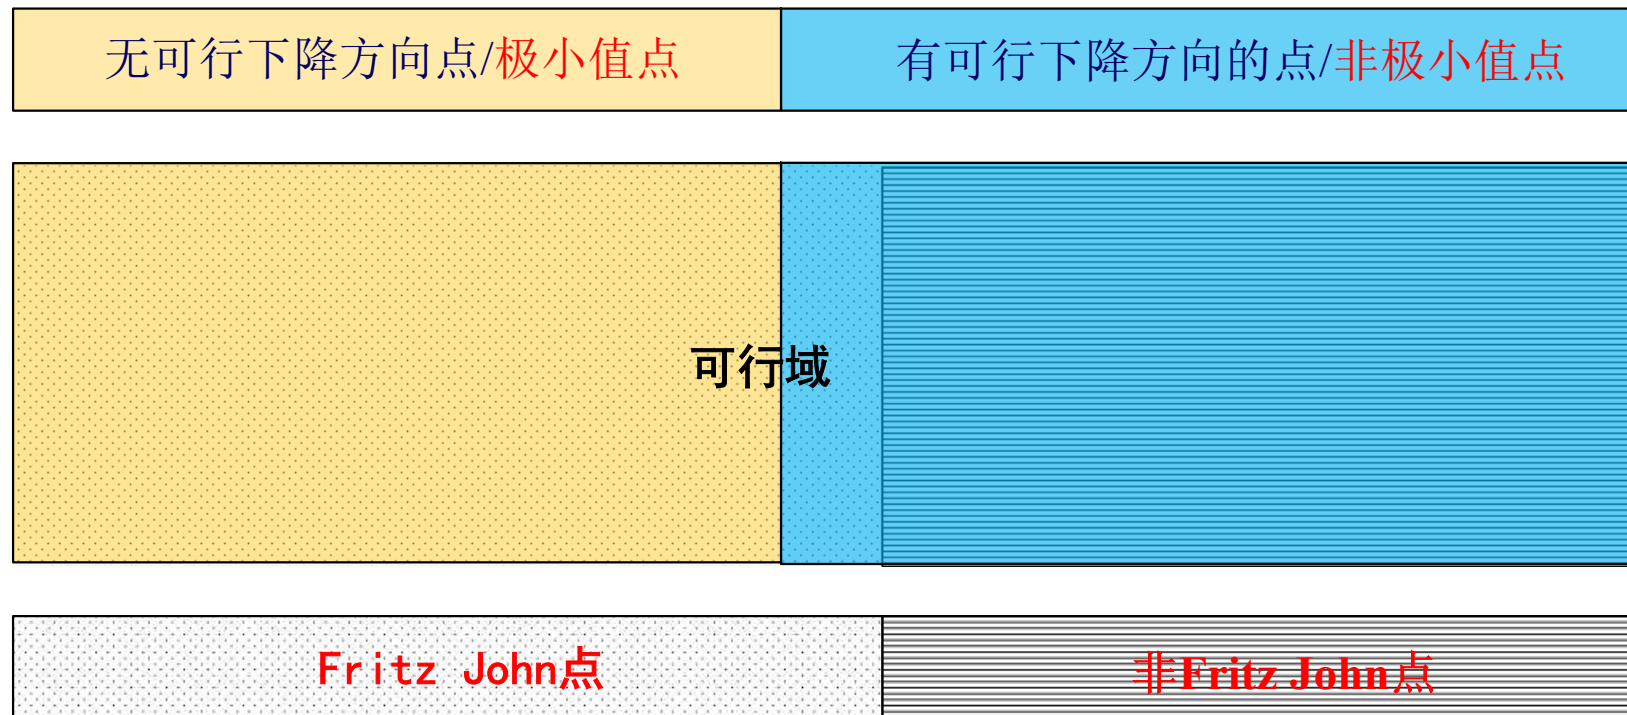
$\eta = 0$: $\mathbf{x}^{(k)}$ 为原非线性规划问题的Fritz John点

$\eta > 0$: 会不会出现?

$\eta = 0$ 时是否是极小值?

$$\begin{aligned} & \min \eta \\ \text{s.t.} \quad & \nabla f(\mathbf{x}^{(k)})^T \mathbf{p} \leq \eta \\ & -\nabla g_j(\mathbf{x}^{(k)})^T \mathbf{p} \leq \eta \quad j \in J \\ & -1 \leq \mathbf{p} \leq 1 \end{aligned}$$

Zoutendijk法集合分析



Fritz John点

不存在与 $\nabla f(\mathbf{X})$ 和所有 $-\nabla g_{j \in J}(\mathbf{X})$ 夹角大于90方向的点
 $\nabla f(\mathbf{X})$ 和 $-\nabla g_{j \in J}(\mathbf{X})$ 正线性相关的点
等价问题最优值 $\eta^*=0$ 的点

非Fritz John点

存在与 $\nabla f(\mathbf{X})$ 和所有 $-\nabla g_{j \in J}(\mathbf{X})$ 夹角大于90方向的点
 $\nabla f(\mathbf{X})$ 和 $-\nabla g_{j \in J}(\mathbf{X})$ 不是正线性相关的点
等价问题最优值 $\eta^*<0$ 的点

$\eta^*=0$ 只能找到Fritz John点，但未必是极值点！

约束极值问题的数值解

- 可行方向法
 - **Zoutendijk可行方向法**
- **约束函数法**
 - 外点法
 - 内点法
 - 混合法
- 逐次逼近法（近似规划法）
 - **SLP (Sequential Linear Programming)**
 - **SQP (Sequential Quadratic Programming)**

制约函数法

- 思想：化为无约束极值问题求解，
- 名称：也称为序列无约束极小化技术，
SUMT(Sequential Unconstrained Minimization Technique)
- 制约函数法的种类
 - 外点法
 - 从可行域外部逼近极值
 - 内点法
 - 从可行域内部逼近极值
 - 混合法
 - 内点法和外点法的结合


外点法

● 构造罚函数

$$\min P(\mathbf{x}, M) = f(\mathbf{x}) + M \sum_{i=1}^m h_i^2(\mathbf{x}) + M \sum_{j=1}^l [\min(0, g_j(\mathbf{x}))]^2$$

Courant 罚函数

$M > 0$ 为罚因子，当 M 趋向无穷时， \mathbf{x}^* 为原问题约束极值解。




解析分析举例

$$\min f(\mathbf{x}) = \frac{1}{3}(x_1 + 1)^3 + x_2$$

$$\text{s.t. } x_1 - 1 \geq 0$$

$$x_2 \geq 0$$

$$\nabla f(\mathbf{x}) = \begin{bmatrix} (x_1 + 1)^2 \\ 1 \end{bmatrix} \neq 0$$



没有内点极值

求解

构造罚函数：

$$P(\mathbf{x}, M) = \frac{1}{3}(x_1 + 1)^3 + x_2 + M[\min(0, x_1 - 1)]^2 + M[\min(0, x_2)]^2$$

根据一阶驻点条件，有

$$\frac{\partial P}{\partial x_1} = (x_1 + 1)^2 + 2M[\min(0, x_1 - 1)] = 0$$

$$\frac{\partial P}{\partial x_2} = 1 + 2M[\min(0, x_2)] = 0$$

如果 $x_1 \geq 1 \Rightarrow x_1 = -1$ ，矛盾

如果 $x_2 \geq 0 \Rightarrow 1 = 0$ ，不成立

所以考虑 $x_1 < 1, x_2 < 0$ 区域的驻点。

$$\frac{\partial P}{\partial x_1} = (x_1 + 1)^2 + 2M(x_1 - 1) = 0$$

$$\frac{\partial P}{\partial x_2} = 1 + 2Mx_2 = 0$$

可得：

$$\begin{cases} x_1 = -1 - M \pm \sqrt{M^2 + 4M} \\ x_2 = -\frac{1}{2M} \end{cases} \quad \begin{matrix} \mathbf{M} \rightarrow +\infty \\ \Rightarrow \end{matrix} \quad \begin{cases} x_1^* = 1 \\ x_2^* = 0 \end{cases}$$

$$\nabla^2 P(\mathbf{x}) = \begin{bmatrix} 2(x_1 + 1) + 2M & 0 \\ 0 & 2M \end{bmatrix} > 0$$

故为极小值

外点法的数值解法

- 构造罚函数

$$\min P(\mathbf{x}, M_k) = f(\mathbf{x}) + M_k \sum_{i=1}^m h_i^2(\mathbf{x}) + M_k \sum_{j=1}^l [\min(0, g_j(\mathbf{x}))]^2$$

- 1、取 $M_1 > 0$ （通常 $M_1 = 1$ ），允许误差 $\varepsilon > 0$ ， $k := 1$
- 2、求 $\min P(\mathbf{x}, M_k)$ ，得 $\mathbf{x}^{*(k)}$ 。
- 3、若存在 $-g_j(\mathbf{x}^{*(k)}) > \varepsilon$ 或 $|h_i(\mathbf{x}^{*(k)})| > \varepsilon$ ，取 $M_{k+1} = cM_k$ ($c > 1$, 通常取5或10)， $k := k+1$ 转第2步重新求解。否则，停止迭代， $\mathbf{x}^* = \mathbf{x}^{*(k)}$ 。

定理：若 $\varepsilon > 0$ ，上述算法必在有限步内终止。

外点法聚点分析

➤ 罚函数

$$P(\mathbf{x}, M_k) = f(\mathbf{x}) + M_k \sum_{i=1}^m h_i^2(\mathbf{x}) + M_k \sum_{j=1}^l [\min(0, g_j(\mathbf{x}))]^2$$

➤ 第k步罚函数的局部极小值满足

$$\nabla P(\mathbf{x}^{*(k)}, M_k) = \nabla f(\mathbf{x}^{*(k)}) + 2M_k \sum_{i=1}^m h_i(\mathbf{x}^{*(k)}) \nabla h_i(\mathbf{x}^{*(k)}) + 2M_k \sum_{g_j(\mathbf{x}_k^*) \leq 0} g_j(\mathbf{x}^{*(k)}) \nabla g_j(\mathbf{x}^{*(k)}) = 0$$

$$\nabla P(\mathbf{x}^{*(k)}, M_k) = \nabla f(\mathbf{x}^{*(k)}) - \sum_{i=1}^m \lambda_i^*(k) \nabla h_i(\mathbf{x}^{*(k)}) - \sum_{g_j(\mathbf{x}_k^*) \leq 0} \mu_j^*(\mathbf{x}_k^*) \nabla g_j(\mathbf{x}^{*(k)}) = 0$$

$$\lambda_i^*(k) = -2M_k h_i(\mathbf{x}^{*(k)})$$

$$\mu_i^*(k) = -2M_k g_j(\mathbf{x}^{*(k)}) \geq 0$$

➤ \mathbf{x}_k^* 迭代收敛时

$$\nabla P(\mathbf{x}^*, M) = \nabla f(\mathbf{x}^*) - \sum_{i=1}^m \lambda_i^* \nabla h_i(\mathbf{x}^*) - \sum_{g_j(\mathbf{x}^*) \rightarrow 0} \mu_j^* \nabla g_j(\mathbf{x}^*) = 0$$

外点法特点

1、只有 $M \rightarrow \infty$ ，才能保证 $\lambda^*(k) \rightarrow \lambda^*$ 、 $\mu^*(k) \rightarrow \mu^*$ ， $x_k^* \rightarrow x^*$ 。
为减小收敛点的误差，需 $M_k \rightarrow \infty$ 。

2、 M_k 过大，有可能导致Hesse矩阵病态（条件数很大），极小值将位于狭长的深谷，导致目标函数值对搜索方向敏感。

$$\text{cond}(\mathbf{H}) = \|\mathbf{H}\| \cdot \|\mathbf{H}^{-1}\| \geq \lambda_{\max} / \lambda_{\min}$$

3、改进策略

1) 设计精确罚函数（例如 l_1 罚函数），令有限 M_k 的 $P(x, M_k)$ 驻点恰好为 x^* 。

2) 构造增广Lagrange函数对罚函数进行修正，在有限 M_k 时也能使 x_k^* 逼近最优解 x^* 。

内点法

- 构造障碍函数

$$\min_{\mathbf{x} \in R_0} \bar{P}(\mathbf{x}, r) = f(\mathbf{x}) + r \sum_{j=1}^l \frac{1}{g_j(\mathbf{x})}$$

或

$$\min_{\mathbf{x} \in R_0} \bar{P}(\mathbf{x}, r) = f(\mathbf{x}) - r \sum_{j=1}^l \log g_j(\mathbf{x})$$

其中 $R_0 = \{\mathbf{x} \mid g_j(\mathbf{x}) > 0, j = 1, 2, \dots, l\}$ 严格内点

$r > 0$ 为障碍因子，其在迭代中的取值会不断减小，趋向于0，使 \mathbf{x} 可趋向于边界。

解析分析举例

$$\min f(\mathbf{x}) = x_1 + x_2$$

$$\mathbf{s.t.} \quad -x_1^2 + x_2 \geq 0$$

$$x_1 \geq 0$$

求解

构造障碍函数：

$$\bar{P}(\mathbf{x}, r) = x_1 + x_2 - r \cdot [\log(-x_1^2 + x_2) + \log(x_1)]$$

根据驻点一阶条件，有

$$\frac{\partial \bar{P}}{\partial x_1} = 1 - r \cdot \frac{-2x_1}{-x_1^2 + x_2} - r \cdot \frac{1}{x_1} = 0$$

$$\frac{\partial \bar{P}}{\partial x_2} = 1 - r \cdot \frac{1}{-x_1^2 + x_2} = 0$$


求解得到：

$$x_1 = \frac{\sqrt{1+8r}-1}{4}$$

$$x_2 = \frac{3}{2}r - \frac{\sqrt{1+8r}-1}{8}$$

$r \rightarrow 0$ 时，有

$$\begin{cases} x_1^* = 0 \\ x_2^* = 0 \end{cases}$$



数值解法

● 构造障碍函数

$$\min_{\mathbf{x} \in R_0} \bar{P}(\mathbf{x}, r_k) = f(\mathbf{x}) - r_k \sum_{j=1}^l \log g_j(\mathbf{x})$$

1、取 $r_1 > 0$ （通常 $r_1 = 1$ ），允许误差 $\varepsilon > 0$ ， $k := 1$

2、求 $\min P(\mathbf{x}, r_k)$ ，得 $\mathbf{x}^{*(k)} \in R_0$ （须保证是内点）

3、若存在 $\left| r_k \sum_{j=1}^l \log g_j(\mathbf{x}^{*(k)}) \right| > \varepsilon$

取 $r_{k+1} = r_k / c$ ，（ $c > 1$, 通常取5或10）， $k := k + 1$ 转第2步重新求解。否则，停止迭代， $\mathbf{x}^* = \mathbf{x}^{*(k)}$ 。

定理：若 $\varepsilon > 0$ ，上述算法必在有限步内终止。

说明：对于复杂问题，初始内点可用算法获取。

内点法聚点分析

➤ 障碍函数

$$\bar{P}(\mathbf{x}, r_k) = f(\mathbf{x}) - r_k \sum_{j=1}^l \log g_j(\mathbf{x})$$

➤ 第k步障碍函数局部极小值满足

$$\nabla \bar{P}(\mathbf{x}_k^*, r_k) = \nabla f(\mathbf{x}_k^*) - r_k \sum_{j=1}^l \frac{1}{g_j(\mathbf{x}_k^*)} \nabla g_j(\mathbf{x}_k^*) = 0$$

$$\nabla \bar{P}(\mathbf{x}_k^*, r_k) = \nabla f(\mathbf{x}_k^*) - \sum_{j=1}^l \mu_j^*(k) \nabla g_j(\mathbf{x}_k^*) = 0$$

$$\mu_j^*(k) = \frac{r_k}{g_j(\mathbf{x}_k^*)} \geq 0$$

➤ \mathbf{x}_k^* 迭代收敛时

$$\nabla \bar{P}(\mathbf{x}^*, r) = \nabla f(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = 0$$

$$\mu_j^* = \frac{r}{g_j(\mathbf{x}^*)} \geq 0$$

$$\mu_j^* g_j(\mathbf{x}^*) = r = 0$$

说明： 对于复杂问题，初始内点可用算法获取。

混合法

- 内点法不能处理等式约束问题
- 外点法不能处理目标函数在可行域外不存在的问题
- 对等式约束和当前不被满足的不等式约束，使用罚函数法，对满足的不等式约束，使用障碍函数法。

约束极值问题的数值解

- 可行方向法
 - **Zoutendijk**可行方向法
- 制约函数法
 - 外点法
 - 内点法
 - 混合法
- 逐次逼近法（近似规划法）
 - **SLP (Sequential Linear Programming)**
 - **SQP (Sequential Quadratic Programming)**

逐次逼近法

- 思想: **Taylor**展开近似为简单规划问题
- 序贯线性规划法**SLP (Sequential Linear Programming)**
- 序贯二次规划法**SQP (Sequential Quadratic Programming)**

一般约束极值问题

$$\min f(\mathbf{x})$$

$$\text{s.t.} \quad h_i(\mathbf{x}) = 0 \quad i = 1, 2, \dots, m$$

$$g_j(\mathbf{x}) \geq 0 \quad j = 1, 2, \dots, l$$

$$\mathbf{x} \in R^n$$

求解思路：通过低阶近似，化为容易求解的规划问题

序贯线性规划法SLP

$$\min f(\mathbf{x}) = f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)})$$

$$\text{s.t.} \quad h_i(\mathbf{x}^{(k)}) + \nabla h_i(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) = 0 \quad i = 1, 2, \dots, m$$

$$g_j(\mathbf{x}^{(k)}) + \nabla g_j(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) \geq 0 \quad j = 1, 2, \dots, l$$

$$|x_s - x_s^{(k)}| \leq \delta_s^{(k)} \quad s = 1, 2, \dots, n \quad \delta_s^{(k)} \text{是步长限制量}$$

设第 k 步线性规划的最优解为 $\mathbf{x}^{*(k)}$

当 $\mathbf{x}^{*(k)}$ 是可行解时，取 $\delta_s^{(k+1)} = \delta_s^{(k)}$, $\mathbf{x}^{(k+1)} = \mathbf{x}^{*(k)}$ 继续迭代;

当 $\mathbf{x}^{*(k)}$ 不是可行解时，取 $\delta_s^{(k)} = \beta \delta_s^{(k)}$, $\beta < 1$, 重新寻优;

当 $|\delta_s^{(k)}| < \varepsilon, \forall s = 1, 2, \dots, n$ 时, 或 $\|\nabla f(\mathbf{x}^{(k)})\| < \varepsilon$ 迭代结束。

序贯二次规划法SQP

起作用约束集法序贯求解如下近似问题

$$\min f(\Delta \mathbf{x}) = f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)})^T \Delta \mathbf{x} + \frac{1}{2} \Delta \mathbf{x}^T \nabla^2 f(\mathbf{x}^{(k)}) \Delta \mathbf{x}$$

$$\text{s.t.} \quad h_i(\mathbf{x}^{(k)}) + \nabla h_i(\mathbf{x}^{(k)})^T \Delta \mathbf{x} = 0 \quad i = 1, 2, \dots, m$$

$$g_j(\mathbf{x}^{(k)}) + \nabla g_j(\mathbf{x}^{(k)})^T \Delta \mathbf{x} \geq 0 \quad j = 1, 2, \dots, l$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \Delta \mathbf{x}^*$$